Visualizing Language Models

Tobias Hodel, Sebastian Flick, Reinhard Priber, Christa Schneider, Jonas Widmer Digital Humanities, dh@wbkolleg.unibe.ch

Introduction

Language models are essential to succeed in NLP tasks such as Part-of-Speech-Tagging and Named Entity Recognition. Since the advent of *word2vec* and large transformer-based language models (such as *BERT* or *GPT-3*) a variety of specialized and fine-tuned language models is currently available. Nonetheless, our in-depth understanding of such a models is limited at best.

In order to strengthen our knowledge of language models and to start the process of reflecting them, we are searching for creative ways of visualizing language models. We envision 3D-visualizations based on dimension reduction to identify the positioning of homonyms in vector spaces.

In our understanding, homonyms are words which share the same spelling but not the same meaning (homographs). Until today, this kind of homonyms is known to cause difficulties when processed in language models, as they are treated as one single element regardless to their semantic differences.

By using current frameworks [Akbik et al. 2019] which embed tokens ("words") as parts of sentences, semantic and grammatical context plays an important role. Based on these contexts, homographs can for example be compared, when visualized even physically.

This leads us to new discussions and first very simple explanations of the inner functions of language models. As such models are currently implemented in tools (like search engines) and machines (like smartphones) that we use daily, we can expect to deal with other, even more complex questions.

Methods/Workflow

In order to make language models visually approachable we:

- Based on textual data from the Königsfelden corpus (for details see below)
- Trained a forward and backward character-based language model (vectorization of textual data) from scratch using flair NLP, not based on any pre-trained models [2096 dimensions]
- Vectorized 30 sentences containing homographs from the corpus
- Stored in a database for further use
- Reduced to three dimensions by applying PCA
- Visualized in a svelte frontend
- Deployed as a docker-image

Code

URL: https://github.com/DHBern/lm_viz

Dataset

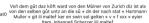
URL: https://koenigsfelden.uzh.ch

Charters and Records of Königsfelden Abbey (1308-1662). Prepared as a scholarly edition. Halter-Pernet et al. 2021: https://koenigsfelden.uzh.ch.

Results

URL: https://nlp-hack-4.fdn-dev.iwi.unibe.ch

Label 1 "stat" (city, place of execution, instead)



ati if f vo dez Mülliz güt von Zurich von dem güt daz hie nach stat *
ze Sarmenstorf sold ue pelisahi hem ze Sarmenstorf
* und daz dis war si und stet belibe * so geben wir disen brief
at2 unserr herschaft versigelt mit der stat insigel von Bruke * sid wir
nitt diegen insige haben

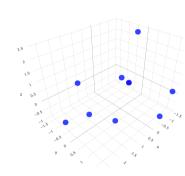
der vorgenanten lute bet * haben unser stat insigel gehenket an t3 disen brief * ze einem offen urkunde * der dingen die da vor geschriben stant

ch des vorgenanden güttes des gnanden convenz rechter were vür eigen und vogteige als da vorgeschriben stat an allen dien stetten da si werscheft bedurfen von mir oder minen erbens Chürnad den schultheiss » « den rat und min buorger gemeinlich tataf von Arowe daz si ir stat ingesigel ze einer gezügsami dis köfes hat gehenckt an diese briefe Wir der Schultheiss

der rat und dit gemeinde vorgenande wan dir köf vor uns beschach und mit urteilde gevertgot wart nach nach unser sta gewonheit und rechte mit allen dien gedingen als davor geschriben

stat dur bette des vorgenan Ulrich unsers burgers han wir tat7 gehencket unser stat ingesigel ze einer gezügsami dis köfes une enkeinr werscheft anders sunderlich an disen stat dur bette des vorgenan Ülrich unsers burgers han wir tat8 gehenchet unser stat ingesingt zeigen reafünsen; die köfes un

stat hat gewert und ez in minen nutz han bekeret dez ich stat9 offenlich vergihe an disem briefe * da von vergih ôch ich * d ich



Label 2 "burg" (castle, person & place name)

Schenko * R* Vinsler * R* Sauenwiler * burger * ze Brugge *

g0 Dietrich von Lenzeburg burg * und and' erb' lûte genûg* * * *

Köninefalden

uf den gûtern in dem Aygen ze Prukke ∗ uf dem Pôz perg und rg1 anderswo als die brief sagent die der vorgnant unser oheim von Nellem - burg ∗ von

darzu verzigen si sich geistliches und welthes gerichtes *
urg2 gewonheit der stete und des landes fries rechtes burg rechtes
und gemeinlich * aller der dinge da mite
Allen den die disen brief ansehent oder hörent lesen nu oder hie

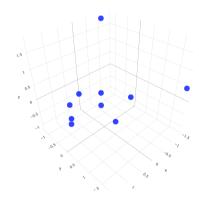
urga nach + Künden wir Johans Scherer schult heis ze der Nüwen Regensperg * und die burger * die ze der selben burg den gründen * in aller der weise * alz unser getruwe * brüder Peter von Stoffeln * cömentür ze Tannenfels Hug von Güten burg * Wernher Trüchselts von Rinwelden und Heinrich von Rinach * sundernt und usscheident * und under marksteinent * und von Ülichen und Altsechte inzer zuren, ab hohlt zenes-

gunst und willen geben haben und
Königsfelden 333 wist umb j hus zû Lentzbûrg * K H 8
urg6 Staatsarchiv AARGAU 366 * diz ist der prieff von dez hus
wegenze Lentz burg *

den burg graben ze Habspurg den Rüdl Engelman buwet und gechdiet in daz burglehen ze Habspurg und der egenannten miner herrschaft von Osterreich ledig * worden ist von Heintzhr den lebenden * und geben ouch in dem namen als davor

den lebenden * und geben ouch in dem namen als davor wissentlich mit disem briefe * für frej bedig eigen * den främvalt * und das hötz * gelegen under der burg ze Brunegg * in Ergöw * das man von alter nennet den Hag und des ze urkünd so henk ich der obgenanten lantvogt min

burg9 burg9 eygen ingesigel an disen brief der geben ist ze Baden uff de burg an sant Margereten tag * do man zalt von cristus gebür drühundert * eins und achtzig Jar



Label 3 "schriben" (written, writing)

* daz dis allez daz hie vor ge- schriben ist * stête belibe * dar uber geben wir disen brief * versigelt * mit ûnserm insigel * und mit dem insigel brûder Heinrich von Talhein de ze den ziten

ben1 dorfren * gar * und genzlich wider geben ze lösende * un * drissig * mark geistlicher fröwen stat ze ire und ze ir nachkomen * hånde

hriben2 für verköft ist * vier mütt roggen * ein malter habern * ein halb swin sol öch ein wolt oder enmöht der sol und mach einen andern erbern

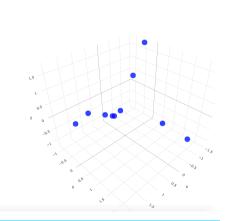
riben3 knecht in die vorgenannte giselschaft schriben und legen der an siner stat ze glicher und sinen brûder schriben mir järzitbûch und inen ir jarzitt

ùch darumb schriben das ich hoften ir kemind àn verzicher denn wir än ùch als unseren oberen zu den sachen nitt geantwurten könden noch zetüend wisten + meinten si nit

schriben lassen das si und im teil der gült von junckher Albrecht von Rinach verwist stent nach innhalt disz briefs etcf und die vi mitt kermengelts ist dahar + bisz uff und hieruff zü merer sicherheit aller vor und nachgeschriben

ze Brugg die mich mitt Hansen Zülöf iren dickgenannten ir ze Brugg die mich mitt Hansen Zülöf iren dickgenannten ir liben8 Zü vogt geben hand sölich des Stapfers angeben und schrift vorgemeldether in schriben lassen und anstatt und für als vor stat dejobt * sölich lichen und

*und her in schriben und setzen l\u00e4ssen * * item des erste ben9 ein gross acker ist der l\u00fctpreistrye widen hat vor Hansz Geiszlier umb den landteil litt an dem kilchweg







Digital Humanities
Universität Bern
Walter Benjamin Kolleg
Mittelstrasse 43
3012 Bern